UNIVERSIDAD DEL VALLE DE GUATEMALA · CIENCIA DE DATOS

DS

Análisis exploratorio de datos

Preferencia humana en batallas de modelos de lenguaje: el caso de Chatbot Arena

Dataset · Kaggle — LMSYS: Chatbot Arena Human Preference Predictions

Proyecto 2 — Reto 10: Predicción de preferencia en batallas de Chatbot Arena

Integrantes: Javier López
Pedro Ávila
Brandon Rivera
Grupo: 5

13 de septiembre de 2026

Contenido

1. Introducción y marco conceptual
   - 1.1 Contexto: evaluación de LLM por preferencia humana
   - 1.2 Técnicas de PLN relevantes para el problema
   - 1.3 Sesgos conocidos en la evaluación por preferencia
2. Situación problemática
3. Problema científico
4. Objetivos
   - 4.1 Objetivo general
   - 4.2 Objetivos específicos
5. Descripción de los datos
   - 5.1 Origen y estructura del conjunto de datos
   - 5.2 Diccionario de variables originales
   - 5.3 Ejemplo ilustrativo de una batalla
6. Limpieza y preprocesamiento
   - 6.1 Verificación de integridad
   - 6.2 Consistencia del voto y construcción de la variable winner
   - 6.3 Decodificación del texto y variables derivadas
   - 6.4 Tratamiento de datos faltantes y atípicos
7. Análisis exploratorio de datos
   - 7.1 Variables y observaciones tras el preprocesamiento
   - 7.2 Estadística descriptiva de las variables cuantitativas
   - 7.3 Variables categóricas: tablas de frecuencia
   - 7.4 Distribuciones: histogramas, cajas y dispersión
   - 7.5 Cruce de variables y sesgos de evaluación
   - 7.6 El modelo que responde: tasas de victoria
   - 7.7 Correlaciones entre variables
   - 7.8 Valores atípicos
8. Hallazgos y conclusiones
   - 8.1 Resumen de hallazgos
   - 8.2 Respuesta al problema científico
   - 8.3 Siguientes pasos propuestos
9. Referencias

Apéndice A — Diccionario completo de variables derivadas
Apéndice B — Tasa de victoria por modelo (ranking completo)
Apéndice C — Frecuencia por familia de modelo (listado completo)

1. Introducción y marco conceptual

1.1 Contexto: evaluación de LLM por preferencia humana

Los modelos de lenguaje de gran escala (LLM, por sus siglas en inglés) ya no se comparan únicamente con benchmarks estáticos de respuesta única, como MMLU o HellaSwag, porque ese tipo de métricas no captura bien la calidad conversacional que percibe una persona real. Chatbot Arena, la plataforma desarrollada por LMSYS y descrita por Chiang et al. (2024), propone en su lugar comparaciones pareadas: un usuario escribe un mensaje (*prompt*), dos modelos anónimos responden en paralelo, y el usuario elige la respuesta que prefiere o declara un empate. Acumulando miles de estos votos es posible ajustar un ranking de tipo Elo o Bradley–Terry sobre los modelos participantes.

Este mecanismo de comparación pareada es también la base del aprendizaje por refuerzo con retroalimentación humana (RLHF): se entrena un modelo de recompensa (*reward model*) a partir de pares de respuestas etiquetadas por preferencia humana, y ese modelo se usa después para ajustar el LLM mediante técnicas como PPO o DPO. La competencia de Kaggle en la que se basa este trabajo, *LMSYS – Chatbot Arena Human Preference Predictions*, plantea exactamente el primer paso de ese proceso: predecir el voto humano a partir del texto de la conversación, es decir, aprender un modelo de recompensa razonable.

1.2 Técnicas de PLN relevantes para el problema

Para un problema de Procesamiento del Lenguaje Natural (PLN) de este tipo, la literatura ofrece varias familias de técnicas, de menor a mayor complejidad:

- **Representación léxica clásica**: bolsa de palabras (*bag-of-words*), TF-IDF y n-gramas. Capturan qué palabras aparecen y con qué frecuencia; son económicas de calcular y suelen ser el primer modelo de referencia en clasificación de texto.
- **Métricas de superficie**: longitud en caracteres o palabras, número de turnos, uso de formato (markdown, listas, negritas, bloques de código), legibilidad. No entienden el contenido semántico, pero son proxies muy usadas del "esfuerzo" o la "calidad percibida" de una respuesta.
- **Embeddings semánticos**: representaciones vectoriales densas (word2vec, sentence-transformers) que capturan similitud de significado más allá de las palabras exactas.
- **Modelos transformer preentrenados y ajuste fino**: BERT, RoBERTa, DeBERTa u otros LLM ajustados sobre tripletas (prompt, respuesta A, respuesta B) para clasificar o ordenar directamente la preferencia; es el enfoque de mejor desempeño reportado para este tipo de tareas.

- **LLM como juez** (*LLM-as-a-judge*): usar un LLM de alta capacidad como árbitro que compara dos respuestas y explica su elección (Zheng et al., 2023). Esta es precisamente la técnica que originó el propio dataset de Chatbot Arena y sirve como referencia de qué tan bien puede imitar el criterio humano un evaluador automático.

1.3 Sesgos conocidos en la evaluación por preferencia

La investigación de Zheng et al. (2023) documenta sesgos sistemáticos en los evaluadores —tanto humanos como LLM-jueces— que motivan varias de las variables que se derivan más adelante en este informe para poder medirlos con datos reales:

- **Sesgo de verbosidad** (*verbosity bias*): tendencia a preferir la respuesta más larga, independientemente de si es más correcta o útil.
- **Sesgo de posición** (*position bias*): tendencia a favorecer la respuesta que aparece en cierta posición, A o B.
- **Sesgo de autopreferencia** (*self-enhancement bias*): un juez LLM tiende a preferir respuestas generadas por modelos de su misma familia.
- **Sesgo de formato**: el uso de markdown, listas y encabezados aumenta la calidad percibida de una respuesta aunque el contenido de fondo sea equivalente.

A partir de este marco, el análisis exploratorio de las secciones 5 a 7 se enfoca en cuantificar, con los datos reales de la competencia, si estos sesgos documentados en la literatura están presentes: el balance de la variable objetivo (A, B o empate), la relación entre longitud de respuesta y victoria, el efecto del formato markdown, la magnitud del sesgo de posición y qué tan informativa resulta la identidad del modelo que responde.

2. Situación problemática

Los modelos de lenguaje se evalúan cada vez menos con benchmarks estáticos y cada vez más con **preferencias humanas**. Chatbot Arena (LMSYS) es una plataforma donde un usuario escribe un prompt, dos modelos anónimos responden en paralelo y el usuario vota cuál respuesta prefiere, o declara un empate. Con millones de votos acumulados se construye un ranking de tipo Elo de los modelos participantes.

El problema es que recolectar votos humanos es costoso y lento, y además se sabe que las personas tienen sesgos sistemáticos al votar: prefieren respuestas más largas (sesgo de verbosidad), respuestas con formato enriquecido (markdown, listas, negritas), y tienden a favorecer la respuesta que aparece en cierta posición (sesgo de posición). Un modelo de recompensa entrenado de forma ingenua sobre estos votos hereda esos mismos sesgos, lo que puede degradar la calidad real de los modelos ajustados con RLHF a partir de él.

3. Problema científico

> **PREGUNTA DE INVESTIGACIÓN**
>
> Dado un prompt y dos respuestas generadas por dos LLM distintos, ¿es posible predecir qué respuesta preferirá un usuario humano —A, B o empate— a partir del texto de la conversación? Y, de forma complementaria, ¿qué características medibles de las respuestas (longitud, formato, modelo que la generó, número de turnos, entre otras) explican esa preferencia?

Responder esta pregunta es el primer paso hacia la construcción de un modelo de recompensa que sea a la vez preciso y menos susceptible a los sesgos descritos en la sección 1.3. El presente informe se concentra en la primera mitad del problema —el análisis exploratorio de los datos disponibles—, dejando el entrenamiento de un modelo predictivo propiamente dicho para una fase posterior del proyecto.

4. Objetivos

4.1 Objetivo general

Realizar un análisis exploratorio del conjunto de datos de Chatbot Arena para comprender la estructura de las batallas y los factores asociados a la preferencia humana, como base para un futuro modelo predictivo de preferencia.

4.2 Objetivos específicos

1. Describir y limpiar el conjunto de datos —variables, observaciones, valores faltantes, duplicados y respuestas nulas— y derivar variables cuantitativas a partir del texto de las conversaciones.
2. Cuantificar la relación entre la preferencia del usuario y características medibles de las respuestas: longitud, diferencia de longitud, uso de formato markdown, número de turnos y modelo que responde.
3. Identificar los sesgos presentes en los votos —verbosidad, posición, empates— y su magnitud, para decidir qué variables y qué tratamiento del texto conviene usar en una futura fase de modelado.

5. Descripción de los datos

5.1 Origen y estructura del conjunto de datos

El conjunto de datos proviene de la competencia de Kaggle *LMSYS – Chatbot Arena Human Preference Predictions* y corresponde al archivo `train.csv`, con **57,477 filas y 9 columnas** en su versión original. Cada fila representa una **batalla**: una conversación de uno o más turnos enviada simultáneamente a dos modelos de lenguaje distintos, junto con el voto emitido por un usuario humano.

5.2 Diccionario de variables originales

Tabla 1. Diccionario de variables originales de `train.csv`

Variable	Tipo (pandas)	Tipo estadístico	Valores únicos
`id`	int64	Identificador	57,477
`model_a` , `model_b`	str	Categórica nominal	64
`prompt`	str (lista JSON)	Texto	51,734
`response_a`	str (lista JSON)	Texto	56,566
`response_b`	str (lista JSON)	Texto	56,609
`winner_model_a`	int64	Binaria (objetivo)	2
`winner_model_b`	int64	Binaria (objetivo)	2
`winner_tie`	int64	Binaria (objetivo)	2

La variable objetivo es, por lo tanto, **multiclase con tres categorías** (gana A, gana B o empate). No existen variables numéricas "nativas" además de los indicadores binarios del voto: toda la información predictiva se encuentra en el texto y en los nombres de los modelos, por lo que en la etapa de preprocesamiento (sección 6) se derivan variables cuantitativas a partir de ese texto.

5.3 Ejemplo ilustrativo de una batalla

Para dar una idea concreta del contenido del dataset, la siguiente batalla real ilustra el formato de los datos: dos modelos de la familia GPT-4 respondieron el mismo prompt y el usuario prefirió la respuesta del modelo A.

EJEMPLO — MODELO A: GPT-4-1106-PREVIEW | MODELO B: GPT-4-0613 | VOTO: GANA A

Prompt: “Is it morally right to try to have a certain percentage of females on managerial positions?”

Respuesta A (ganadora): “The question of whether it is morally right to aim for a certain percentage of females in managerial positions is a complex ethical issue that involves considerations of fairness, equality, diversity, and discrimination. Here are some arguments in favor of and against such policies: **Arguments in favor:** 1. **Correcting Historical Inequities:** Women have historically been underrepresented in leadership roles due to various cultural, institutional, and social barriers…”

Respuesta B: “As an AI, I don't have personal beliefs or opinions. However, I can tell you that the question of gender quotas in managerial positions is a complex one and positions can vary. Advocates argue that such measures can help correct historical imbalances, promote diversity, and may lead to better decision-making. Critics may argue that positions should be based purely on merit…”

Nótese cómo la respuesta ganadora (A) es más larga, usa formato markdown (negritas, lista numerada) y desarrolla explícitamente los dos lados del argumento, mientras que la respuesta B es más breve y directa. Este patrón —longitud y formato asociados a la victoria— se confirma de manera sistemática en el análisis de la sección 7.

6. Limpieza y preprocesamiento

Sobre el conjunto de datos original se realizaron las siguientes tareas de limpieza y preprocesamiento:

6.1 Verificación de integridad

No se encontraron valores faltantes en ninguna de las 9 columnas originales. Tampoco hay identificadores (`id`) duplicados, pero sí se detectaron **7 filas completamente duplicadas** (mismo prompt, mismas respuestas y mismo voto, ignorando el `id`), las cuales se eliminaron, dejando **57,470 batallas** para el análisis.

6.2 Consistencia del voto y construcción de la variable `winner`

Se verificó que, en cada fila, exactamente una de las columnas `winner_model_a`, `winner_model_b` y `winner_tie` vale 1 (las otras dos valen 0); esto se cumple en el 100% de las 57,477 filas originales. A partir de esas tres columnas *one-hot* se construyó una única variable categórica `winner` $\in$ {A, B, tie}, que se usa como objetivo en todo el análisis posterior.

6.3 Decodificación del texto y variables derivadas

Las columnas `prompt`, `response_a` y `response_b` están almacenadas como cadenas de texto en formato JSON, con un elemento de lista por cada turno de la conversación. Se decodificaron a listas de Python, contando los turnos en los que la respuesta es `null` (el modelo no respondió). Se verificó además que el número de turnos de `prompt`, `response_a` y `response_b` coincide en el 100% de las batallas.

Sobre el texto decodificado se derivó, por batalla y sumando todos los turnos, un conjunto de variables cuantitativas:

- `n_turns`: número de turnos de la conversación.
- `prompt_len`, `len_a`, `len_b`: longitud en caracteres del prompt y de cada respuesta; `words_a`, `words_b`: número de palabras de cada respuesta.
- `len_diff = len_a - len_b` y `len_ratio = len_a / len_b`: diferencia y razón de longitud entre las dos respuestas.
- Indicadores de formato: número de bloques de código, ítems de lista, encabezados y negritas en cada respuesta, agregados en `fmt_a` y `fmt_b`.
- `null_a`, `null_b`: la respuesta es nula o vacía en al menos un turno.
- `same_model`: indica si el modelo A y el modelo B son el mismo.

- `family_a`, `family_b`: familia del modelo (gpt-4, claude, llama, mistral, gemini, entre otras) para reducir la cardinalidad de 64 modelos a 31 familias.

6.4 Tratamiento de datos faltantes y atípicos

No se eliminó ninguna batalla por longitud de las respuestas: las longitudes extremas son observaciones reales y se tratan mediante transformación logarítmica en los gráficos (sección 7.4) en lugar de recortarse. Las respuestas nulas o vacías se conservaron como una variable indicadora (`null_a`, `null_b`) en vez de imputarse o eliminarse, porque resultan informativas: como se muestra en la sección 7.5, una respuesta nula casi siempre pierde la batalla. Del conjunto original solo se eliminaron los 7 duplicados exactos mencionados en la sección 6.1; no se realizó ninguna otra eliminación de filas.

7. Análisis exploratorio de datos

7.1 Variables y observaciones tras el preprocesamiento

Tras la limpieza descrita en la sección 6, el conjunto de trabajo queda con **57,470 observaciones** (batallas) y crece de **9 variables originales a 41 columnas** una vez incorporadas las variables intermedias de texto y las derivadas cuantitativas y categóricas. De estas, 26 son las variables analíticas propiamente dichas —18 cuantitativas y 8 categóricas o binarias—, cuyo diccionario completo se presenta en el Apéndice A.

7.2 Estadística descriptiva de las variables cuantitativas

La Tabla 2 resume las variables cuantitativas más relevantes para el problema. Todas las variables de longitud, palabras y formato muestran una **asimetría positiva muy marcada** (coeficientes de asimetría entre 5 y más de 100), es decir, distribuciones con una cola larga hacia la derecha: la mayoría de las respuestas son cortas y con poco formato, pero existe una minoría de respuestas extremadamente largas o con mucho formato que arrastra la media muy por encima de la mediana. Por esta razón, en los gráficos de la sección 7.4 se usa una escala logarítmica y, para resumir, se prioriza la mediana y los percentiles altos por encima de la media.

Tabla 2. Estadística descriptiva de las variables cuantitativas principales (n = 57,470)

Variable	Media	Mediana	Desv. estándar	P95	Máximo	Asimetría
n_turns	1.24	1	0.91	2	36	9.24
prompt_len	352.4	91	1,025.4	1,419	32,833	8.58
len_a	1,330.5	1,036	1,461.9	3,584	53,299	5.01
len_b	1,337.3	1,044	1,483.8	3,576	52,402	5.52
words_a	212.4	169	226.3	559	9,184	5.17
words_b	213.2	171	228.6	559	8,173	5.48
len_diff (A−B)	−6.8	0	1,061.1	1,449	43,003	−1.10
len_ratio (A/B)	2.48	1.00	31.55	5.43	4,825	104.4
fmt_a	4.48	0	9.29	20	288	6.20
fmt_b	4.48	0	9.18	20	222	5.60

fmt_a / fmt_b = número de elementos de formato markdown (código + listas + encabezados + negritas) en la respuesta. El desglose de code_a/b, lists_a/b, headers_a/b y bold_a/b se presenta en el Apendice A. Dada la fuerte asimetría de estas variables, la mediana y los percentiles altos son más representativos que la media.

Las variables `len_a` y `len_b` tienen distribuciones prácticamente idénticas entre sí (medias de 1,330 y 1,337 caracteres, medianas de 1,036 y 1,044), lo cual es consistente con que los modelos se asignan aleatoriamente a las posiciones A y B. El prompt es mucho más corto que las respuestas: su mediana es de apenas 91 caracteres frente a los >1,000 caracteres de una respuesta típica. Los indicadores de formato (`fmt_a`, `fmt_b`) tienen mediana 0 —la mayoría de las respuestas no usa ningún elemento de markdown— pero colas muy largas, con hasta 263 bloques de código en una sola respuesta.

7.3 Variables categóricas: tablas de frecuencia

La variable objetivo está razonablemente **balanceada** entre sus tres clases (Tabla 3): un clasificador trivial que siempre prediga la clase mayoritaria acertaría apenas un 34.9% de las veces, y el empate —con 30.9% de los casos— es una clase casi tan grande como las otras dos, lo que hace este problema más difícil que una comparación binaria simple.

Tabla 3. Distribucion de la variable objetivo `winner`

Resultado	Frecuencia	Proporcion
A (gana modelo A)	20,063	34.9%
B (gana modelo B)	19,649	34.2%
Empate	17,758	30.9%

La gran mayoría de las conversaciones consta de un único turno (86.9%); la cola llega hasta 36 turnos en casos excepcionales (Tabla 4). No se encontró ninguna batalla en la que el modelo A y el modelo B fueran el mismo, y las respuestas nulas o vacías son un fenómeno raro, presente en apenas 0.2%–0.3% de las batallas por lado (Tabla 5).

Tabla 4. Frecuencia del número de turnos por conversación

N.° de turnos	Frecuencia	Proporcion
1	49,932	86.9%
2	4,672	8.1%
3	1,485	2.6%
4	607	1.1%
5	311	0.5%
6	167	0.3%

Tabla 5. Indicadores binarios de calidad de los datos

Indicador	Verdadero	Proporcion
`same_model` (A y B son el mismo modelo)	0	0.0%
`null_a` (respuesta A nula/vacía en algún turno)	133	0.2%
`null_b` (respuesta B nula/vacía en algún turno)	143	0.2%

N.° de turnos	Frecuencia	Proporcion
7	103	0.2%
8	60	0.1%
9	44	0.1%
10 o más	89	0.2%

En cuanto a los modelos que participan en las batallas, hay **64 modelos distintos**, con una distribución muy desigual: los 20 modelos más frecuentes concentran el 64.2% de todas las apariciones (Tabla 6), y al agruparlos en 31 familias, las familias GPT-4, Claude y GPT-3.5 concentran por sí solas el 41% de las apariciones (Tabla 7).

Tabla 6. Los 20 modelos que más aparecen en el dataset (de 64 modelos distintos)

Modelo	Apariciones (A + B)	% del total
gpt-4-1106-preview	7,386	6.4%
gpt-3.5-turbo-0613	7,080	6.2%
gpt-4-0613	6,164	5.4%
claude-2.1	5,583	4.9%
claude-instant-1	4,134	3.6%
gpt-4-0314	4,122	3.6%
claude-1	3,978	3.5%
vicuna-33b	3,720	3.2%
mixtral-8x7b-instruct-v0.1	3,545	3.1%
vicuna-13b	3,447	3.0%
llama-2-70b-chat	3,427	3.0%
gpt-3.5-turbo-1106	3,352	2.9%
mistral-medium	3,315	2.9%
llama-2-13b-chat	2,606	2.3%
claude-2.0	2,455	2.1%
zephyr-7b-beta	2,401	2.1%
palm-2	1,977	1.7%

Modelo	Apariciones (A + B)	% del total
llama-2-7b-chat	1,793	1.6%
wizardlm-70b	1,644	1.4%
openchat-3.5	1,632	1.4%

Los 20 modelos más frecuentes concentran el 64.2% de todas las apariciones; la distribución tiene una cola larga de modelos con pocas batallas.

Tabla 7. Familias de modelo más frecuentes (agrupación de los 64 modelos en 31 familias)

Familia	Apariciones (A + B)	% del total
gpt-4	18,832	16.4%
claude	16,150	14.1%
gpt-3.5	12,595	11.0%
llama	10,514	9.1%
vicuna	8,758	7.6%
mistral	6,357	5.5%
mixtral	3,870	3.4%
wizardlm	3,223	2.8%
gemini	2,923	2.5%
chatglm	2,814	2.5%
zephyr	2,813	2.5%
pplx	2,669	2.3%

Las 12 familias listadas concentran cerca del 80% de las apariciones; el listado completo de 31 familias esta en el Apendice C.



Figura 1. Distribución del objetivo, número de turnos por conversación y los 20 modelos más frecuentes.

7.4 Distribuciones: histogramas, cajas y dispersión

Los histogramas en escala logarítmica (Figura 2) confirman la fuerte asimetría reportada en la Tabla 2: al transformar la longitud con $\log_{10}$, tanto el prompt como las dos respuestas se aproximan a una distribución normal, con una pequeña acumulación cerca de cero que corresponde a respuestas vacías o muy cortas.

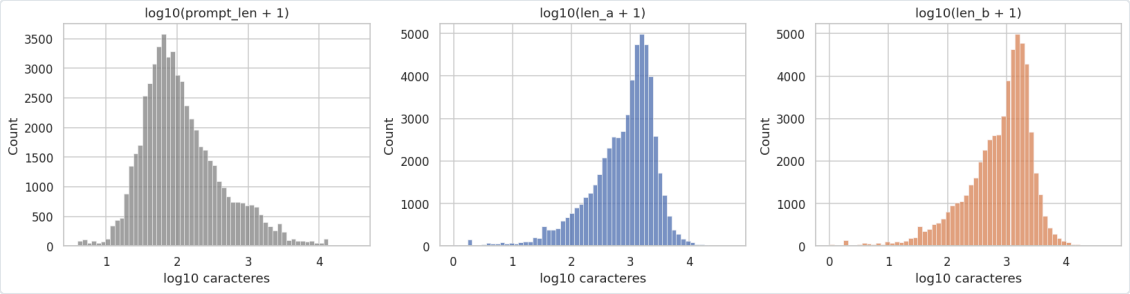


Figura 2. Histogramas de la longitud (en log10 de caracteres) del prompt y de cada respuesta.

Los diagramas de caja de la Figura 3 muestran que la respuesta ganadora tiende a ser más larga: cuando gana A, la mediana de `len_a` (1,241 caracteres) es notablemente mayor que la mediana de `len_b` (961 caracteres), y el patrón se invierte simétricamente cuando gana B (Tabla 8). En la razón de longitud A/B, la mediana se desplaza por encima de 1 cuando gana A y por debajo de 1 cuando gana B, mientras que los empates se concentran alrededor de una razón de 1, es decir, respuestas de longitud similar.

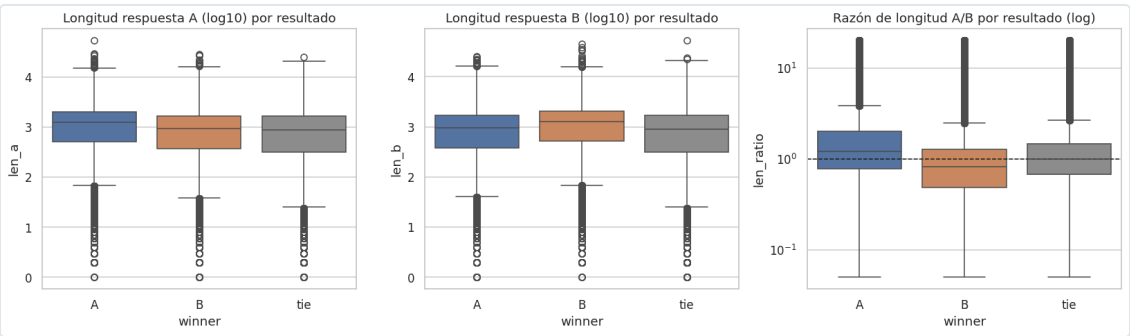


Figura 3. Diagramas de caja de la longitud de cada respuesta y de su razón A/B, según el resultado de la batalla.

Tabla 8. Longitud y formato mediano de cada respuesta según el resultado de la batalla

Resultado	len_a (mediana)	len_b (mediana)	fmt_a (mediana)	fmt_b (mediana)	n_turns (mediana)
Gana A	1,241	961	0	0	1
Gana B	943	1,259	0	0	1
Empate	890	888	0	0	1

El gráfico de dispersión (Figura 4), que compara la longitud de A contra la de B para una muestra aleatoria de batallas, muestra que los puntos donde gana A se ubican mayoritariamente por debajo de la diagonal (A más larga que B) y los de "gana B" por encima, pero con un solapamiento considerable: la longitud explica una parte relevante del voto, pero claramente no toda.

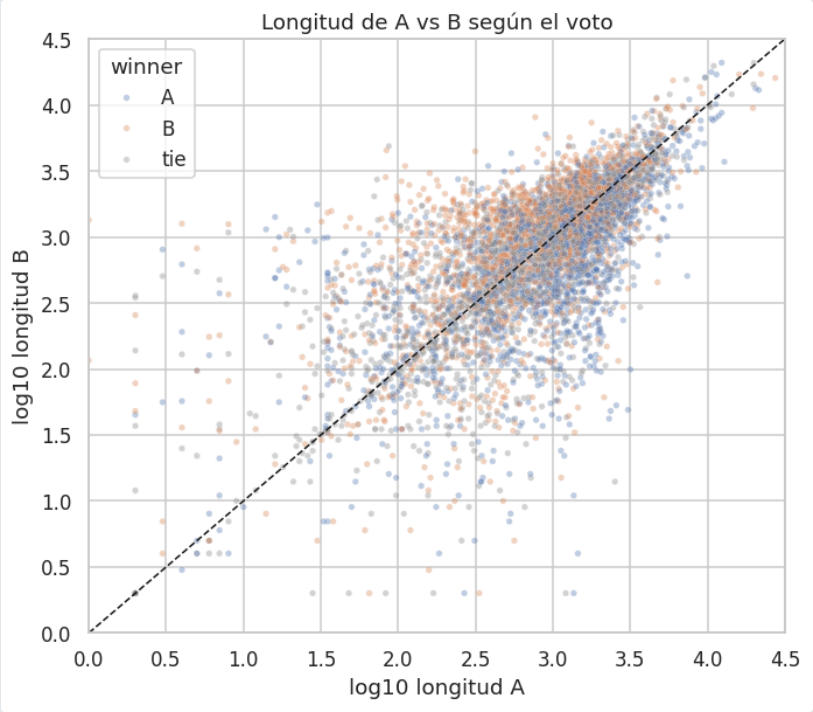


Figura 4. Longitud de la respuesta A contra la longitud de la respuesta B (escala log10), coloreada por el resultado de la batalla.

7.5 Cruce de variables y sesgos de evaluación

Esta sección retoma directamente los sesgos descritos en la sección 1.3 y los cuantifica con los datos de la competencia.

Sesgo de verbosidad

Cuando una de las dos respuestas es más larga que la otra, esa respuesta más larga gana en torno al 43% de las veces frente a un 27% de la más corta (Tabla 9); el resto son empates. Si se excluyen los empates, la respuesta más larga gana el **61.5%** de las batallas decididas, y esa probabilidad crece de forma monótona con la magnitud de la diferencia de longitud (Tabla 10 y Figura 5): pasa de 49.5% cuando las longitudes son casi iguales a 68.7% cuando una respuesta es cinco veces más larga que la otra. La correlación de Spearman entre `len_diff` y el objetivo (0.241) es, de hecho, la más alta de todas las variables derivadas (sección 7.7).

Tabla 9. Resultado de la batalla según cual respuesta es más larga

Quien es más larga	P(gana A)	P(gana B)	P(empate)
A más larga	43.1%	26.3%	30.6%
B más larga	27.0%	42.5%	30.5%
Igual longitud	14.5%	10.8%	74.7%

Tabla 10. Probabilidad de que gane la respuesta más larga, según la magnitud de la diferencia (batallas sin empate)

Razon de longitud (más larga / más corta)	P(gana la más larga)	n (batallas)
[1.0 – 1.1)	49.5%	4,759
[1.1 – 1.25)	54.7%	5,535
[1.25 – 1.5)	59.4%	6,612
[1.5 – 2.0)	63.8%	7,673
[2.0 – 3.0)	66.3%	6,241
[3.0 – 5.0)	67.7%	4,150
[5.0 – ∞)	68.7%	4,742

Empates

Los empates son más frecuentes cuando las dos respuestas tienen una longitud parecida (37.7% de empates cuando la razón de longitud es menor a 1.1) y, sobre todo, cuando la longitud es *idéntica* (74.7% de empates en ese caso extremo —Tabla 9, fila "Igual longitud"—), lo que casi siempre corresponde a respuestas iguales o a ambas respuestas vacías. La tasa de empate baja a 25–26% cuando una respuesta es mucho más larga que la otra, y también disminuye en conversaciones con más turnos.

Sesgo de formato y respuestas nulas

La respuesta con más elementos de formato markdown (listas, negritas, encabezados, bloques de código) gana entre 45% y 46% de las veces, frente a 26–27% de la respuesta con menos formato. Este efecto está correlacionado con la longitud —las respuestas más largas tienden también a usar más formato—, por lo que ambos factores deberán separarse en una eventual etapa de modelado. Las respuestas nulas o vacías son raras (0.2–0.3% de las batallas) pero tienen un efecto claro: cuando la respuesta A es nula, B gana el 40% de las veces frente a solo 28% de A; el patrón es simétrico para el caso contrario. Aun así, cerca de un 30% de esas batallas terminan en empate, lo que sugiere cierto ruido en el etiquetado de esos casos.

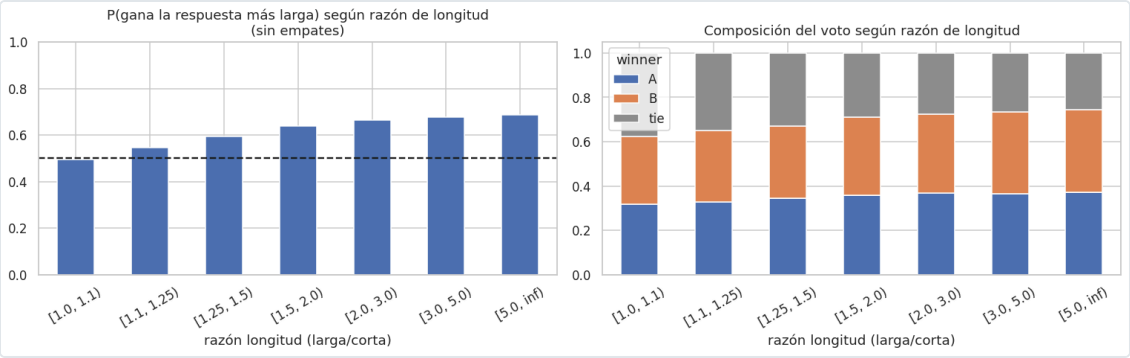


Figura 5. Probabilidad de que gane la respuesta más larga según la razón de longitud, y composición del voto por bins de esa razón.

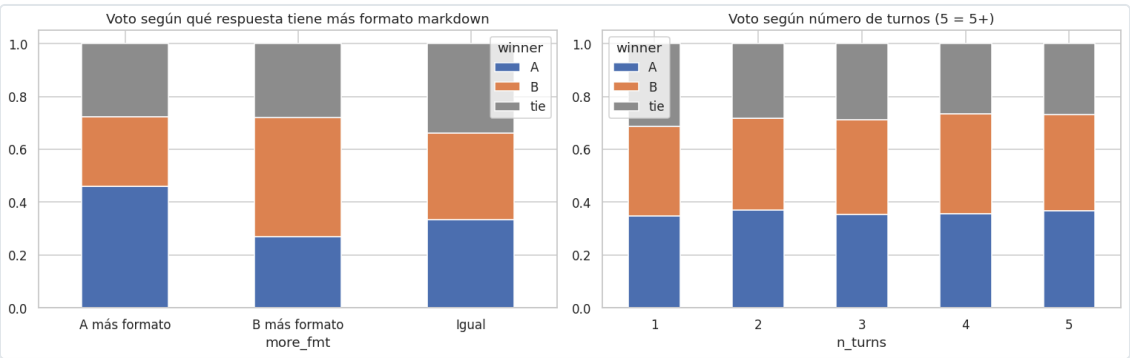


Figura 6. Resultado de la batalla según qué respuesta tiene más formato markdown, y según el número de turnos de la conversación.

Sesgo de posición

Como los modelos se asignan al azar a las posiciones A y B, en ausencia de sesgo se esperaría que P(gana A) = P(gana B). En los datos, A gana el 50.521% de las batallas decididas (sin empates) frente a 49.479% de B; una prueba binomial exacta sobre estas 39,712 batallas da un valor p de **0.038**, es decir, hay una ventaja de la posición A que es estadísticamente detectable, pero de una magnitud pequeña (poco más de un punto porcentual) comparada con el efecto de la longitud. Adicionalmente, la diferencia relativa máxima entre cuántas veces aparece un modelo como A frente a como B es de solo 11.5%, lo que descarta que el sesgo de posición observado se deba a que ciertos modelos se hayan asignado preferentemente a una posición.

7.6 El modelo que responde: tasas de victoria

La identidad del modelo que genera la respuesta resulta muy informativa sobre el resultado de la batalla. La Tabla 11 muestra los extremos del ranking de tasa de victoria (excluyendo empates) entre los 58 modelos con al menos 300 batallas: va de un máximo de **76.0%** para `gpt-4-1106-preview` a un mínimo de **18.6%** para `chatglm2-6b`. El ranking completo, con los 58 modelos, se incluye en el Apéndice B, y se visualiza de forma completa en la Figura 7.

Tabla 11. Extremos del ranking de tasa de victoria por modelo (modelos con ≥ 300 batallas; 58 modelos en total)

Modelo	Batallas	Tasa victoria	Tasa empate	Tasa victoria (sin empates)
gpt-4-1106-preview	7,386	55.1%	27.4%	76.0%
gpt-4-0125-preview	1,160	51.4%	31.2%	74.7%
gpt-3.5-turbo-0314	1,302	54.6%	25.7%	73.5%
gpt-4-0314	4,122	48.4%	29.1%	68.2%
claude-1	3,978	43.9%	29.8%	62.6%
qwen1.5-72b-chat	551	39.0%	32.8%	58.1%
gpt-4-0613	6,164	39.7%	30.2%	56.9%
claude-instant-1	4,134	39.7%	29.3%	56.2%
llama-2-70b-chat	3,427	37.3%	32.4%	55.2%
claude-2.0	2,455	38.9%	29.1%	54.9%
…	…	…	…	…
gpt4all-13b-snoozy	408	22.8%	32.1%	33.6%
RWKV-4-Raven-14B	1,158	22.9%	31.0%	33.2%
mpt-7b-chat	928	23.0%	30.7%	33.1%
oasst-pythia-12b	1,494	23.0%	28.5%	32.1%
fastchat-t5-3b	1,021	19.2%	31.2%	27.9%
chatglm-6b	1,261	17.2%	34.5%	26.3%
stablelm-tuned-alpha-7b	771	17.1%	31.0%	24.8%
chatglm3-6b	989	15.9%	29.7%	22.6%
llama-13b	547	16.1%	28.3%	22.4%
dolly-v2-12b	800	15.5%	30.5%	22.3%
chatglm2-6b	564	12.9%	30.3%	18.6%

Ranking completo de los 58 modelos en el Apendice B. La tasa de victoria sin empates se calcula como tasa_victoria / (1 – tasa_empate).

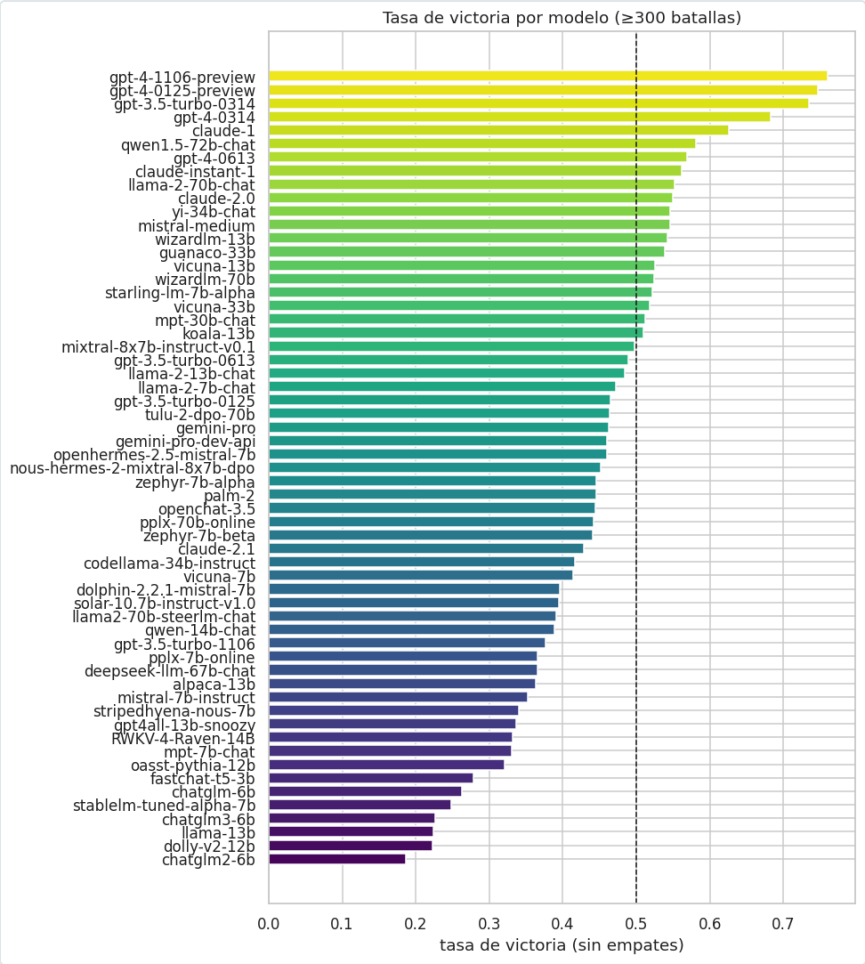


Figura 7. Tasa de victoria (sin empates) por modelo, para los 58 modelos con al menos 300 batallas.

Esta identidad del modelo, sin embargo, **no está disponible en el conjunto de prueba** de la competencia, por lo que solo sirve como variable de análisis exploratorio y no como predictor directo. Es interesante notar que la longitud mediana de las respuestas de un modelo correlaciona de forma considerable con su tasa de victoria (correlación de Spearman de **0.589**, Figura 8), lo que sugiere que parte de la "calidad percibida" de un modelo en este dataset está mediada por qué tan extensas son sus respuestas —aunque hay excepciones notables, como `gpt-3.5-turbo-0314`, que es muy conciso y aun así tiene una tasa de victoria alta.

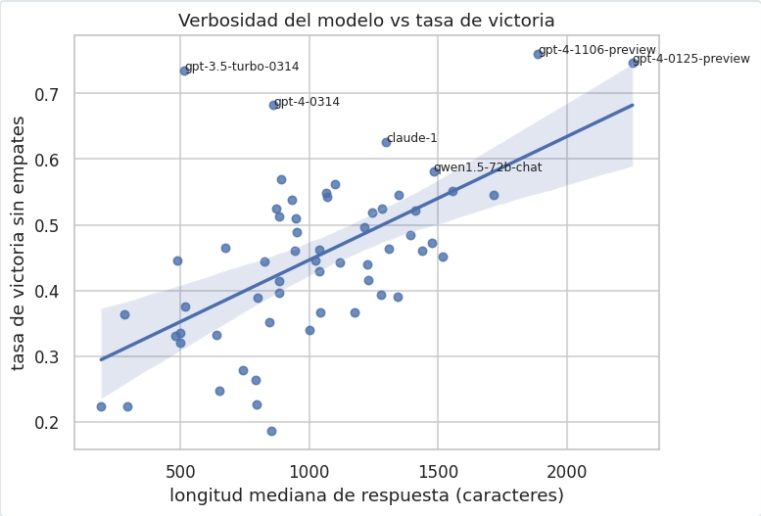


Figura 8. Longitud mediana de respuesta de cada modelo contra su tasa de victoria sin empates.

Finalmente, la matriz de enfrentamientos entre los 12 modelos más frecuentes (Figura 9) muestra que el ranking es, en general, transitivo —`gpt-4` vence a casi todos los demás modelos—, aunque algunas parejas de modelos tienen muy pocas batallas registradas entre sí, lo que hace más ruidosa esa comparación puntual.

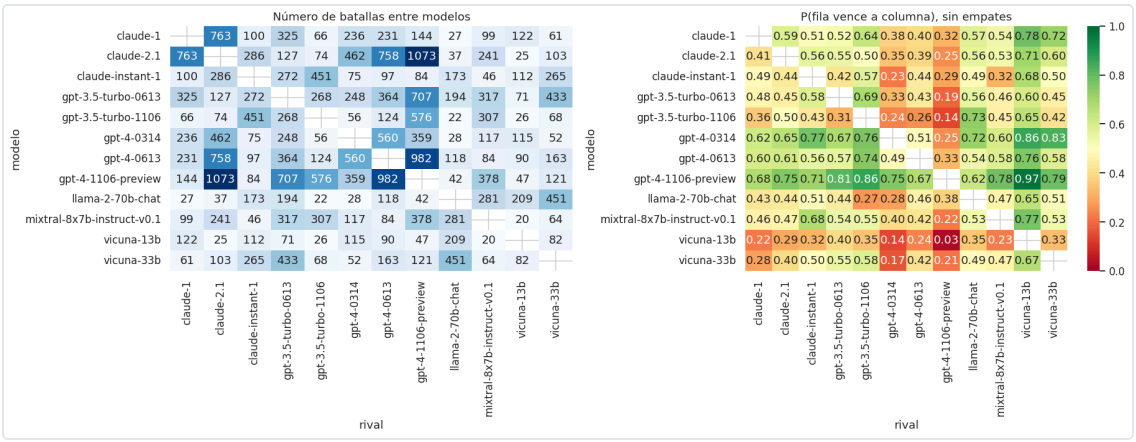


Figura 9. Número de batallas entre los 12 modelos más frecuentes (izquierda) y probabilidad de que el modelo de la fila venza al de la columna, sin empates (derecha).

7.7 Correlaciones entre variables

La Tabla 12 resume la correlación de Spearman entre las principales variables derivadas y el objetivo, codificado numéricamente como A = 1, empate = 0, B = −1. Las correlaciones más fuertes corresponden, como es de esperar dado el análisis anterior, a `len_diff` (0.241) y `len_ratio` (0.222); el resto de las variables de superficie tiene correlaciones débiles, todas por debajo de 0.10 en valor absoluto.

Tabla 12. Correlacion de Spearman entre las variables derivadas y el objetivo (codificado A=1, empate=0, B=−1)

Variable	Correlacion de Spearman con el objetivo
len_diff (A − B)	0.241
len_ratio (A / B)	0.222
words_a	0.100
len_a	0.099
fmt_a	0.080
prompt_len	0.002
n_turns	0.002
fmt_b	−0.081
len_b	−0.094
words_b	−0.094

El mapa de calor completo (Figura 10) muestra además que las variables derivadas del mismo lado de la batalla —longitud, número de palabras y formato del lado A entre sí, y lo mismo para el lado B— están altamente correlacionadas entre ellas, lo cual es esperable (una respuesta más larga tiende a tener más palabras y más elementos de formato) y sugiere cierta redundancia que convendría atender en una fase de selección de variables.

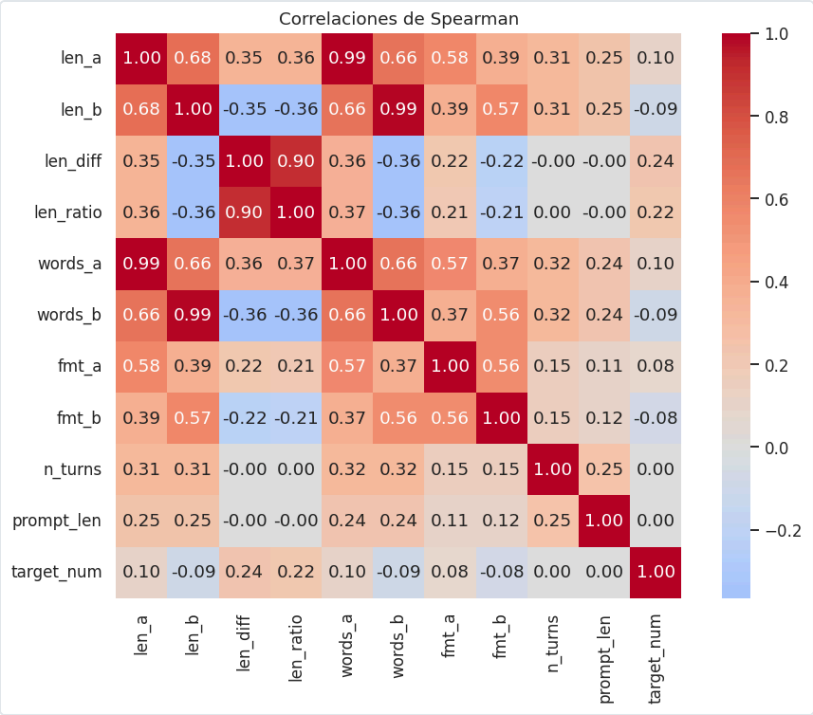


Figura 10. Matriz de correlaciones de Spearman entre las variables numéricas derivadas.

7.8 Valores atípicos

Se definieron como atípicas las batallas con alguna respuesta por encima del percentil 99 de longitud (aproximadamente 6,784 caracteres para A y 6,736 para B). Se identificaron **822 batallas** en esa condición (1.4% del total), generadas predominantemente por modelos de la familia GPT-4, en particular `gpt-4-1106-preview` (Tabla 13). En este subconjunto la respuesta larga gana con más frecuencia todavía que en el resto del dataset, y la proporción de empates baja a 25%.

Tabla 13. Resultado de las 822 batallas con algúna respuesta por encima del percentil 99 de longitud

Resultado	Frecuencia	Proporcion
A	326	39.7%
B	288	35.0%
Empate	208	25.3%

Percentil 99: prompt_len ≈ 4,701 car., len_a ≈ 6,784 car., len_b ≈ 6,736 car. Los 10 modelos más presentes entre estos atípicos son, en orden: gpt-4-1106-preview (187), gpt-3.5-turbo-0613 (71), mistral-medium (67), llama-2-70b-chat (59), mixtral-8x7b-instruct-v0.1 (56), claude-1 (53), gpt-4-0314 (53), claude-2.1 (46), gpt-4-0613 (45) y gpt-4-0125-preview (43).

Se decidió **no eliminar** estas observaciones atípicas: corresponden a respuestas reales, coherentes con el patrón general de que la longitud favorece la victoria, y no parecen ser errores de captura de datos. Para una futura etapa de modelado se recomienda, en cambio, trabajar con transformaciones logarítmicas de la longitud o truncar el texto a una longitud máxima razonable antes de vectorizarlo.

8. Hallazgos y conclusiones

8.1 Resumen de hallazgos

1. El dataset es limpio —sin valores faltantes, con solo 7 duplicados exactos y con un voto perfectamente consistente en cada fila— y está razonablemente balanceado entre las tres clases del objetivo; la mayor dificultad recae en el empate (30.9% de los casos) y en que toda la información predictiva útil está contenida en texto libre.
2. El factor individual más fuerte es la **longitud relativa** de las dos respuestas: la más larga gana el 61.5% de las batallas decididas, hasta un 68.7% cuando la razón de longitud es de 5 o más. El segundo factor en importancia es el **formato markdown**. Ambos reflejan sesgos humanos documentados en la literatura y deberán ser variables base de un futuro modelo predictivo.
3. Los **empates** ocurren predominantemente cuando las dos respuestas son parecidas en longitud o directamente idénticas, y son menos frecuentes en conversaciones largas o con una gran diferencia de longitud entre las respuestas.
4. El **sesgo de posición** es real pero leve: la posición A gana el 50.5% de las batallas decididas (valor p = 0.038 en una prueba binomial), un efecto de apenas un punto porcentual frente al efecto mucho mayor de la longitud.
5. La **identidad del modelo** que responde explica una parte considerable del resultado (tasas de victoria que van de 18.6% a 76.0%), pero esa variable no estará disponible en el conjunto de prueba de la competencia, por lo que un futuro modelo deberá inferir la calidad de una respuesta únicamente a partir de su texto.
6. Las variables derivadas de longitud y formato tienen, en conjunto, correlaciones débiles con el objetivo ($|\rho| \leq 0.24$), por lo que se espera que un modelo basado solo en ellas supere al azar (35%) por un margen modesto. Una fase de modelado posterior deberá incorporar representación del contenido textual —TF-IDF, embeddings o un modelo de lenguaje ajustado como DeBERTa o Gemma— y evaluarse con log-loss multiclase, la métrica oficial de la competencia.

8.2 Respuesta al problema científico

Retomando la pregunta planteada en la sección 3 —¿se puede predecir la preferencia humana (A, B o empate) a partir del texto de la conversación?—, el análisis exploratorio permite dar una respuesta matizada:

1. **Los objetivos específicos definidos en la sección 4.2 se cumplieron** con los datos disponibles: el dataset se describió y se limpió (57,470 batallas sin valores faltantes tras eliminar 7 duplicados), se derivaron variables cuantitativas de longitud, formato y modelo, y se

cuantificó su relación con el voto humano mediante correlaciones de Spearman y pruebas de proporciones.

2. **Los sesgos investigados en la sección 1.3 sí están presentes en los datos.** El sesgo de verbosidad es, de los medibles con este conjunto de variables, el más fuerte (la respuesta más larga gana el 61.5% de las batallas decididas); el sesgo de formato va en la misma dirección que la longitud, y el sesgo de posición existe pero es de magnitud pequeña (50.5% frente a 49.5%, p = 0.038). Este resultado confirma, con datos reales de Chatbot Arena, los hallazgos reportados por Zheng et al. (2023).
3. **Las variables de superficie por sí solas no bastan para resolver el problema.** Sus correlaciones con el objetivo son débiles ($|\rho| \leq 0.24$), de modo que un modelo apoyado únicamente en longitud y formato superaría al azar (35%) solo por un margen modesto. La preferencia humana parece depender, sobre todo, del **contenido** de la respuesta y no únicamente de su forma, lo cual es coherente con lo discutido en la sección 1.2: se necesitará una representación del texto más rica que un simple conteo de caracteres o de elementos de formato.
4. **El empate es la clase más difícil de anticipar** (30.9% de los casos): ocurre cuando las dos respuestas son similares en longitud o en texto, es menos frecuente en conversaciones con más turnos, y ninguna de las variables derivadas en este análisis lo distingue con claridad de las otras dos clases. Este comportamiento requerirá atención especial —por ejemplo, calibración de probabilidades— en una eventual etapa de modelado.

8.3 Siguientes pasos propuestos

- Construir primero un modelo de referencia (*baseline*) con las variables ya derivadas en este informe —longitud, diferencia y razón de longitud, formato, número de turnos—, usando regresión logística multinomial o *gradient boosting*, evaluado con log-loss multiclase, la métrica oficial de la competencia.
- Incorporar una representación del contenido textual: TF-IDF como segundo modelo de referencia y, posteriormente, embeddings o el ajuste fino de un modelo transformer (por ejemplo DeBERTa, Gemma u otro LLM abierto) sobre tripletas (prompt, respuesta A, respuesta B), dado que la sección 7.5 mostró que el contenido explica más que la forma superficial del texto.
- Diseñar la validación cruzada evitando fuga de información entre filas que compartan el mismo prompt o los mismos modelos, y vigilar el desempeño del modelo por separado para empates frente a batallas decididas.
- Corregir, o al menos monitorear, el sesgo de posición detectado —por ejemplo, promediando las predicciones del modelo con las posiciones A y B intercambiadas— para evitar que el modelo aprenda a favorecer una posición en lugar del contenido real de la respuesta.

- Tratar de forma separada el pequeño subconjunto de batallas con respuesta nula (~0.2%) y las de `same_model`, ya que exhiben patrones de empate distintos al resto del conjunto de datos.

9. Referencias

- Chiang, W.-L., Zheng, L., Sheng, Y., Angelopoulos, A. N., Li, T., Li, D., Zhang, H., Zhu, B., Jordan, M., Gonzalez, J. E., & Stoica, I. (2024). *Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference.* Proceedings of the 41st International Conference on Machine Learning (ICML). arxiv.org/abs/2403.04132
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). *Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena.* Advances in Neural Information Processing Systems (NeurIPS). arxiv.org/abs/2306.05685
- Kaggle. *LMSYS – Chatbot Arena Human Preference Predictions* [conjunto de datos y descripción de la competencia]. kaggle.com/competitions/lmsys-chatbot-arena

Apéndice A — Diccionario completo de variables derivadas

Listado completo de las 26 variables cuantitativas, categóricas y binarias construidas durante el preprocesamiento (sección 6), complementario a la Tabla 2 del cuerpo principal del informe.

Tabla A.1. Diccionario completo de las 26 variables cuantitativas y categóricas derivadas en el preprocesamiento (no incluye columnas intermedias de texto ni banderas auxiliares usadas solo para construir tablas y graficos)

Variable derivada	Tipo (pandas)	Tipo estadístico
`n_turns`	int64	Cuantitativa discreta
`prompt_len`	int64	Cuantitativa
`prompt_words`	int64	Cuantitativa
`len_a`	int64	Cuantitativa
`len_b`	int64	Cuantitativa
`words_a`	int64	Cuantitativa
`words_b`	int64	Cuantitativa
`len_diff`	int64	Cuantitativa (diferencia)
`len_ratio`	float64	Cuantitativa (razón)
`code_a`	int64	Cuantitativa discreta
`code_b`	int64	Cuantitativa discreta
`lists_a`	int64	Cuantitativa discreta
`lists_b`	int64	Cuantitativa discreta
`headers_a`	int64	Cuantitativa discreta
`headers_b`	int64	Cuantitativa discreta
`bold_a`	int64	Cuantitativa discreta
`bold_b`	int64	Cuantitativa discreta
`fmt_a`	int64	Cuantitativa discreta
`fmt_b`	int64	Cuantitativa discreta
`winner`	category	Categórica (objetivo, 3 clases)

Variable derivada	Tipo (pandas)	Tipo estadístico
`model_a`	str	Categórica nominal
`model_b`	str	Categórica nominal
`family_a`	str	Categórica nominal
`family_b`	str	Categórica nominal
`same_model`	bool	Binaria
`null_a`	bool	Binaria
`null_b`	bool	Binaria

Apéndice B — Tasa de victoria por modelo (ranking completo)

Ranking completo de los 58 modelos con al menos 300 batallas registradas, ordenado de forma descendente por tasa de victoria sin contar empates. Complementa la Tabla 11 y la Figura 7 de la sección 7.6.

Tabla B.1. Ranking completo de tasa de victoria por modelo (58 modelos con ≥ 300 batallas, orden descendente)

Modelo	Batallas	Tasa victoria	Tasa empate	Tasa victoria (sin empates)
gpt-4-1106-preview	7,386	55.1%	27.4%	76.0%
gpt-4-0125-preview	1,160	51.4%	31.2%	74.7%
gpt-3.5-turbo-0314	1,302	54.6%	25.7%	73.5%
gpt-4-0314	4,122	48.4%	29.1%	68.2%
claude-1	3,978	43.9%	29.8%	62.6%
qwen1.5-72b-chat	551	39.0%	32.8%	58.1%
gpt-4-0613	6,164	39.7%	30.2%	56.9%
claude-instant-1	4,134	39.7%	29.3%	56.2%
llama-2-70b-chat	3,427	37.3%	32.4%	55.2%
claude-2.0	2,455	38.9%	29.1%	54.9%
mistral-medium	3,315	36.8%	32.7%	54.6%
yi-34b-chat	1,447	36.7%	32.8%	54.6%
wizardlm-13b	1,579	36.2%	33.2%	54.2%
guanaco-33b	684	36.0%	33.2%	53.8%
vicuna-13b	3,447	36.1%	31.2%	52.5%
wizardlm-70b	1,644	35.8%	31.8%	52.4%
starling-lm-7b-alpha	1,134	35.4%	32.1%	52.2%
vicuna-33b	3,720	34.1%	34.2%	51.8%
mpt-30b-chat	598	34.6%	32.4%	51.2%
koala-13b	1,598	35.1%	31.0%	50.9%
mixtral-8x7b-instruct-v0.1	3,545	33.7%	32.1%	49.7%

Modelo	Batallas	Tasa victoria	Tasa empate	Tasa victoria (sin empates)
gpt-3.5-turbo-0613	7,080	33.6%	31.3%	48.9%
llama-2-13b-chat	2,606	32.8%	32.1%	48.4%
llama-2-7b-chat	1,793	30.9%	34.5%	47.2%
gpt-3.5-turbo-0125	861	31.1%	33.1%	46.5%
tulu-2-dpo-70b	1,200	31.5%	31.9%	46.3%
gemini-pro	1,437	32.4%	29.9%	46.2%
gemini-pro-dev-api	1,486	32.3%	29.8%	46.0%
openhermes-2.5-mistral-7b	952	29.4%	36.0%	46.0%
nous-hermes-2-mixtral-8x7b-dpo	325	32.6%	27.7%	45.1%
zephyr-7b-alpha	412	28.9%	35.2%	44.6%
palm-2	1,977	32.2%	27.5%	44.5%
openchat-3.5	1,632	29.0%	34.7%	44.4%
pplx-70b-online	1,419	31.6%	28.5%	44.2%
zephyr-7b-beta	2,401	29.7%	32.4%	44.0%
claude-2.1	5,583	30.5%	28.9%	42.9%
codellama-34b-instruct	1,474	29.0%	30.3%	41.6%
vicuna-7b	1,591	28.2%	32.1%	41.4%
dolphin-2.2.1-mistral-7b	373	25.5%	35.7%	39.6%
solar-10.7b-instruct-v1.0	899	26.9%	31.7%	39.4%
llama2-70b-steerlm-chat	667	26.8%	31.3%	39.1%
qwen-14b-chat	1,072	25.7%	33.9%	38.9%
gpt-3.5-turbo-1106	3,352	26.0%	30.9%	37.6%
deepseek-llm-67b-chat	795	23.9%	34.7%	36.6%
pplx-7b-online	1,250	26.2%	28.2%	36.6%
alpaca-13b	1,403	25.4%	30.0%	36.3%
mistral-7b-instruct	1,617	23.9%	32.1%	35.2%
stripedhyena-nous-7b	914	22.5%	33.7%	34.0%
gpt4all-13b-snoozy	408	22.8%	32.1%	33.6%

Modelo	Batallas	Tasa victoria	Tasa empate	Tasa victoria (sin empates)
RWKV-4-Raven-14B	1,158	22.9%	31.0%	33.2%
mpt-7b-chat	928	23.0%	30.7%	33.1%
oasst-pythia-12b	1,494	23.0%	28.5%	32.1%
fastchat-t5-3b	1,021	19.2%	31.2%	27.9%
chatglm-6b	1,261	17.2%	34.5%	26.3%
stablelm-tuned-alpha-7b	771	17.1%	31.0%	24.8%
chatglm3-6b	989	15.9%	29.7%	22.6%
llama-13b	547	16.1%	28.3%	22.4%
dolly-v2-12b	800	15.5%	30.5%	22.3%
chatglm2-6b	564	12.9%	30.3%	18.6%

Apéndice C — Frecuencia por familia de modelo (listado completo)

Listado completo de las 31 familias de modelo identificadas al agrupar los 64 modelos distintos del dataset, complementario a la Tabla 7 de la sección 7.3.

Tabla C.1. Frecuencia de apariciones por familia de modelo (listado completo, 31 familias)

Familia	Apariciones (A + B)	% del total
gpt-4	18,832	16.4%
claude	16,150	14.1%
gpt-3.5	12,595	11.0%
llama	10,514	9.1%
vicuna	8,758	7.6%
mistral	6,357	5.5%
mixtral	3,870	3.4%
wizardlm	3,223	2.8%
gemini	2,923	2.5%
chatglm	2,814	2.5%
zephyr	2,813	2.5%
pplx	2,669	2.3%
qwen	2,031	1.8%
palm	1,977	1.7%
openchat	1,876	1.6%
koala	1,598	1.4%
mpt	1,526	1.3%
oasst	1,494	1.3%
yi	1,447	1.3%
alpaca	1,403	1.2%
tulu	1,200	1.0%

Familia	Apariciones (A + B)	% del total
rwkv	1,158	1.0%
starling	1,134	1.0%
fastchat	1,021	0.9%
nous	914	0.8%
solar	899	0.8%
dolly	800	0.7%
deepseek	795	0.7%
stablelm	771	0.7%
guanaco	684	0.6%
otro	408	0.4%
falcon	286	0.3%